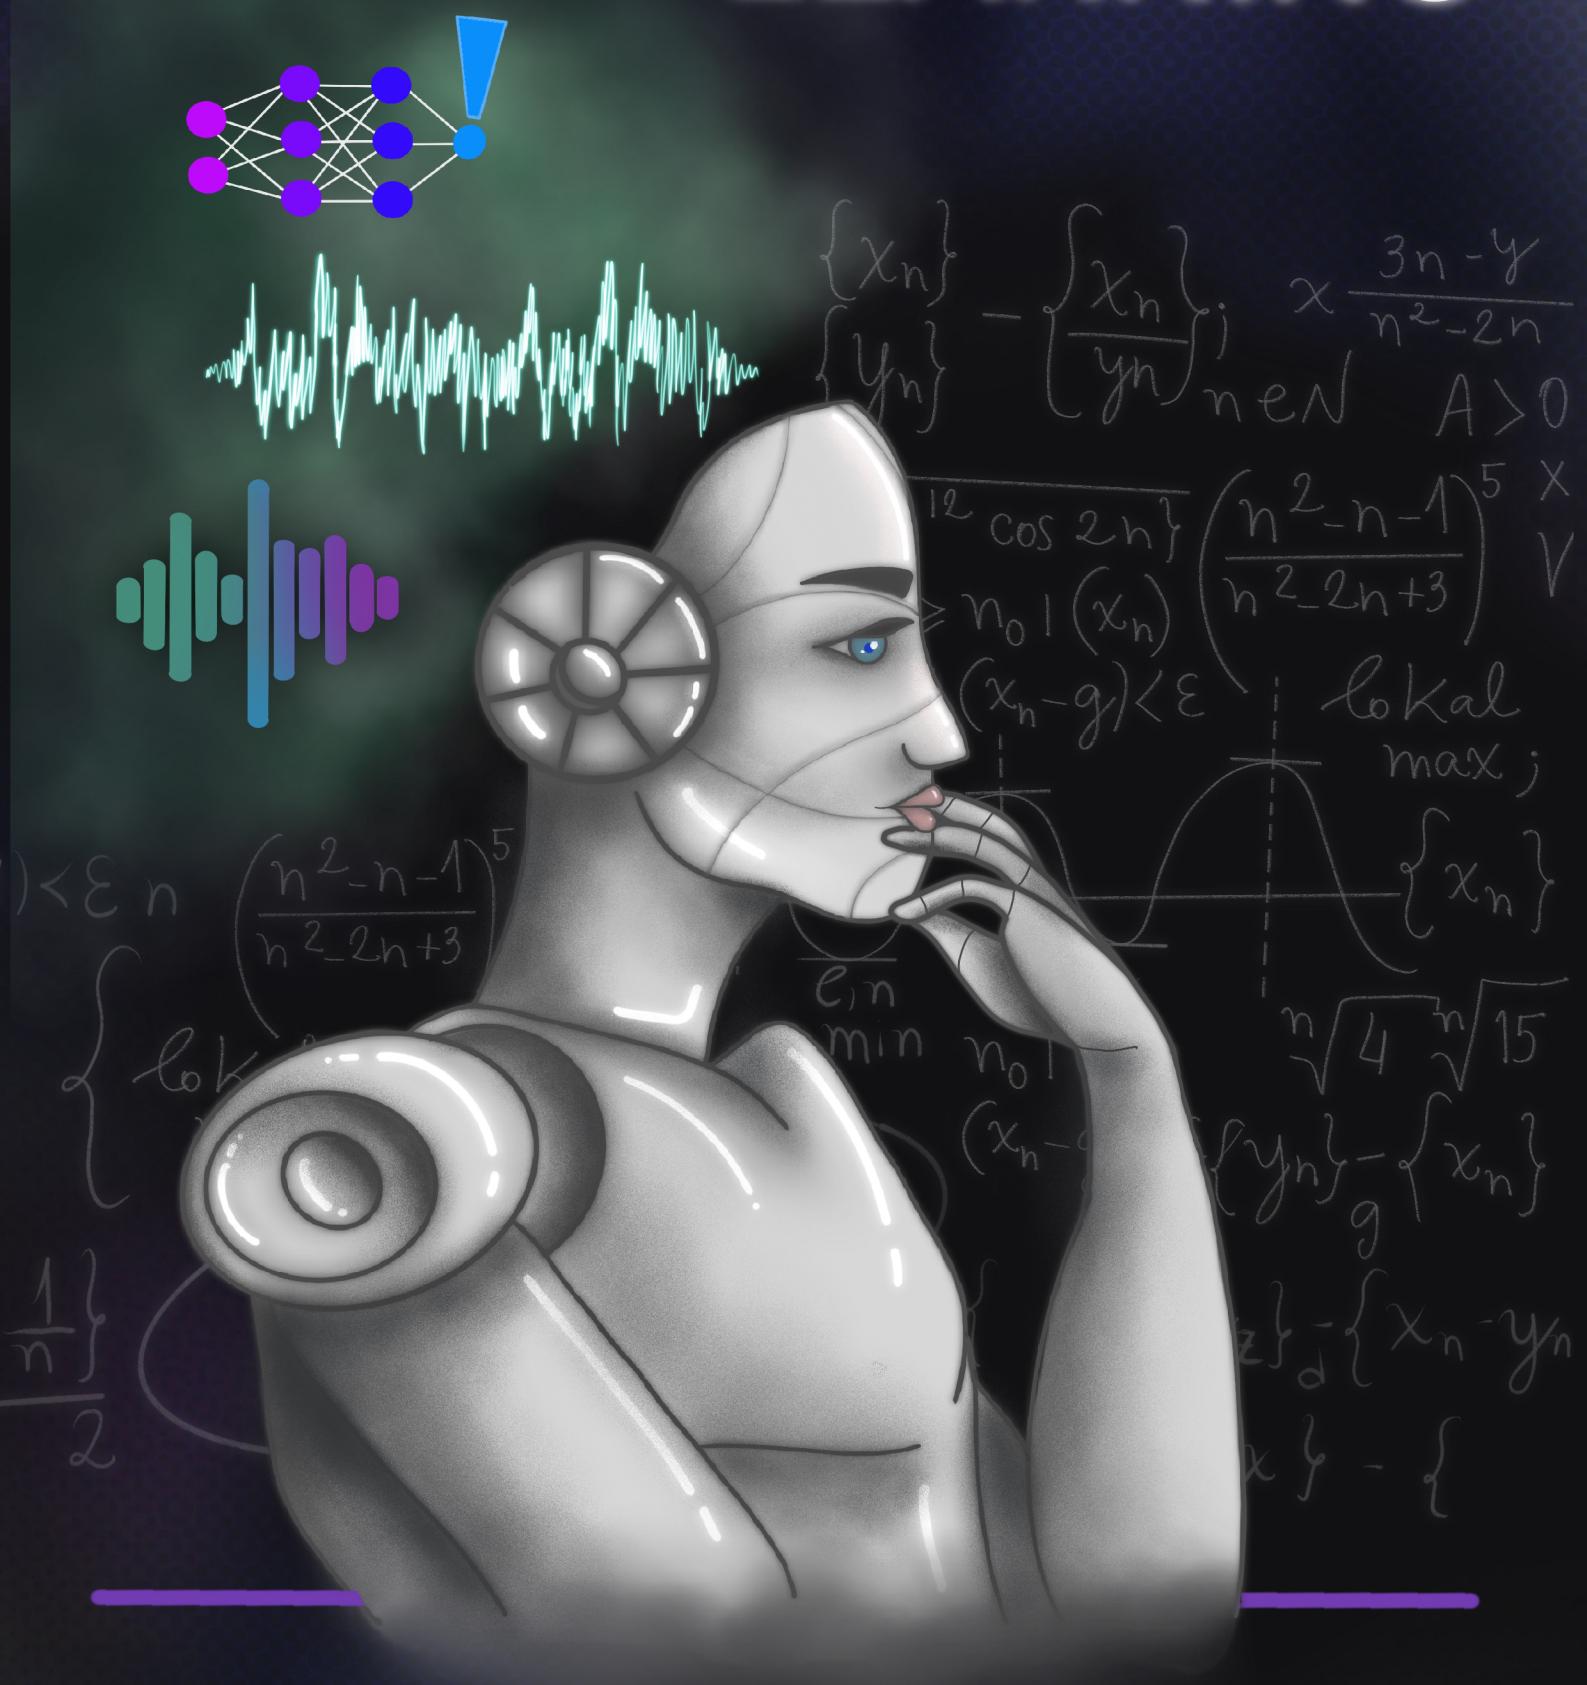


DESMISTIFICANDO O MACHINE LEARNING



Produzido por:



i2AI

A Connected AI World

INTERNATIONAL ASSOCIATION OF ARTIFICIAL INTELLIGENCE

<https://www.i2ai.org/>

Autores:

- Alexandre Nicolau
- Arnaldo de Paula Couto
- Claudio Cardozo
- Daniela Jacobovitz
- Danielle Monteiro
- Dionisio Gava Junior
- Edson Souza Bessa
- Hamilton Tenório da Silva
- Luiz Henrique de O. Bueno

Índice

Desmistificando o Aprendizado de Máquina	3
Sumário	3
Agradecimentos	3
Capítulo 1: Aprendizagem	4
O que é aprendizagem?	4
A capacidade humana	5
A capacidade computacional	6
Capítulo 2: Aprendizado de Máquina	7
O que é o Aprendizado de máquina	7
Abordagens de aprendizado de máquina	8
Aprendizagem supervisionada	8
Aprendizagem não supervisionada	9
Aprendizagem por reforço	9
Métodos e algoritmos utilizados no aprendizado de máquina	10
Classificação	10
Regressão	11
Clustering ou de agrupamento	11
Capítulo 3: Breve retrospectiva sobre I.A. e M.L.	12
Sistemas Especialistas e I.A. Simbólica	16
Aprendizado de Máquina e Aprendizado Profundo (2000s – 2020s)	19
Capítulo 4: Alguns exemplos e aplicações	24
Capítulo 5: Mapa de Métodos e aplicações	28
Referências Bibliográficas	29
Referências das tabelas 2-4	30
Dicionário da nomenclatura técnica, conceitos e informações históricas	32
Sobre os Autores	39

DESMISTIFICANDO O APRENDIZADO DE MÁQUINA

SUMÁRIO

Este e-book foi escrito para explicar de forma simples o que é o Aprendizado de Máquina, em inglês “*Machine Learning*”, para o público em geral e principalmente para aqueles que não são da área de tecnologia. Nas próximas páginas abordaremos de forma crescente os conceitos de aprendizagem e como ele foi aplicado no contexto computacional.

Na evolução deste material, abordaremos também a matemática aplicada - em uma próxima publicação a ser lançada posteriormente - e apresentaremos com exemplos do nosso cotidiano em que essas técnicas são utilizadas de forma transparente. Dado a vasta quantidade de termos técnicos e conceitos que são trazidos no bojo do Aprendizado de Máquina, ao final do e-book, apresentamos um dicionário destes termos, nomenclaturas, significado das abreviações e informações históricas relevantes. Os termos que constam no dicionário estão assinalados com a informação [dic].

AGRADECIMENTOS

Um agradecimento especial a todos os participantes do Comitê de *Machine Learning* da I2AI, que contribuíram com esse livro digital. Sem a colaboração e incentivo de vocês este e-book não seria possível.

Dentre essas pessoas podemos destacar o time responsável por esse material:

[Alexandre Nicolau](#)

[Arnaldo de Paula Couto](#)

[Claudio Cardozo](#)

[Daniela Jacobovitz](#)

[Danielle Monteiro](#)

[Dionisio Gava Junior](#)

[Edson Souza Bessa](#)

[Hamilton Tenório da Silva](#)

[Luiz Henrique de O. Bueno](#)

CAPÍTULO 1: APRENDIZAGEM

O QUE É APRENDIZAGEM?

Aprendizagem é um processo de mudança de comportamento obtido através da experiência construída por fatores emocionais, neurológicos, relacionais e ambientais. Portanto podemos dizer que “aprender” é o resultado da interação entre estruturas mentais e o meio ambiente.

Esse processo - aprendizagem - pode ser medido através das curvas de aprendizagem, que mostram a importância da repetição de certas predisposições fisiológicas, de “tentativa e erro” e de períodos de descanso.

Há um número grande de formas de aprendizagem, dentre as quais podemos citar a adaptação, a correção, a otimização, a representação e a interação.

A aprendizagem humana está ligada à inferência de regras por trás dos padrões e segundo as teorias conexionistas^[dic]. Está relacionada ao número de sinapses ^[dic] feitas pelos neurônios, isso quer dizer que “aprender significa fazer novas conexões”.



Figura 1 - Nuvem de Palavras associadas à "aprendizagem".

A CAPACIDADE HUMANA

Ao contrário de dispositivos eletrônicos como smartphones, tablets e laptops, o cérebro humano parece ter uma capacidade infinita. Ainda assim, muitos de nós temos dificuldade de decorarmos um simples nome, uma data de aniversário ou um número de telefone.

Nossa capacidade de memória tem como base a fisiologia do cérebro, que é composto de aproximadamente 100 bilhões de neurônios. No entanto, apenas 1 bilhão deles tem uma função de armazenamento de recordações antigas, e são chamados de células piramidais.

“A quantidade de neurônios existentes não é suficiente para todas as informações adquiridas por um indivíduo.”

Paul Reber, professor de psicologia da Northwestern University, Estados Unidos.

Vamos utilizar um exemplo para simplificar a nossa capacidade finita de aprender, seja por limitações de memória ou pela simples falta de tempo dedicado a aprender coisas novas. Nossa exemplo será dedicado a uma das profissões mais importantes da humanidade, as Médicas e Médicos.

Quanto tempo livre, durante uma semana, um(a) médico(a) consegue dedicar para leitura dos inúmeros estudos que são publicados regularmente pela comunidade científica? Poucas ou nenhuma.

É neste contexto, mas não limitado a ele, que as tecnologias de aprendizado de máquina têm ajudado a humanidade e a cada dia mais estarão integradas ao nosso dia a dia.

Concluindo nosso exemplo vamos citar uma das tecnologias mais maduras, no momento da confecção deste livro, o IBM Watson Health. Essa solução de tecnologia, desenvolvida pela gigante IBM, é capaz de fazer a “leitura e entendimento” de todas as publicações médicas digitais, desde as mais antigas até as mais recentes e estruturar uma **base de conhecimento** infinitamente maior que qualquer ser humano. Vale ressaltar que, nos Estados Unidos, toda a literatura médica foi digitalizada e está disponível para consulta.

A CAPACIDADE COMPUTACIONAL

Precisamos iniciar esse subtítulo trazendo à tona que o termo “Inteligência Artificial” foi cunhado em 1956 por John McCarthy^[dic], um cientista da computação norte americano.

E por que esse termo se tornou popular mais recentemente? Exatamente porque atualmente o poder computacional e seu acesso popularizado, através de serviços e plataformas disponíveis em nuvem^[dic], permite sua adoção de maneira mais abrangente, desde complexos sistemas computacionais que fazem um veículo ser dirigido sem a intervenção humana até o aplicativo de filtro para deixar as fotos mais bonitas, o qual pode ser instalado no seu smartphone.

Essa capacidade computacional paralela^[dic], processamento de informações em tempo real e outras tecnologias que permitem que uma gigantesca gama de informações seja processada em um curto espaço de tempo, permitiu que as técnicas de matemática e estatística fossem aplicadas em grande escala.

Vamos voltar ao nosso exemplo acima, o IBM Watson Health. O poder computacional possibilitou à IBM o armazenamento, processamento e acesso à toda literatura médica norte-americana, além de estar preparado para suportar as novas publicações geradas pela comunidade médica científica. Com todos esses dados “em mãos”, o IBM Watson é capaz de entender a anamnese^[dic] - entrevista realizada pelo profissional de saúde - pesquisar situações semelhantes (padrões) em sua base de conhecimento e apresentar ao médico as possíveis causas ou prováveis tipologia de doenças, como também indicar os exames clínicos mais apropriados a serem realizados pelo paciente, para melhorar sua assertividade (em termos mais técnicos, a acurácia).

Após a realização dos exames indicados e a atualização de seus resultados dentro da plataforma, ela é capaz de indicar qual é a doença com uma precisão muito maior que qualquer ser humano, reduzindo drasticamente a incidência de diagnósticos errôneos e todos os benefícios que isso traz, seja na saúde do paciente, como também na economia financeira dos operadores de saúde.

Mas como isso é possível? Vamos avançar nos próximos capítulos e entender mais sobre “aprendizado de máquina”.

CAPÍTULO 2: APRENDIZADO DE MÁQUINA

O QUE É O APRENDIZADO DE MÁQUINA

O aprendizado de máquina, em inglês *machine learning* (sigla M.L.), se trata de uma tecnologia que utiliza Inteligência Artificial como base e algoritmos que aprendem interativamente por meio de dados coletados em suas interações.

Com o uso do M.L., nós ensinamos a máquina a aprender as coisas e, assim, realizar determinadas tarefas sozinha.

Imaginemos, por exemplo, que um aplicativo de M.L. tem o objetivo de identificar fotos de frutas em um banco de dados. Neste exemplo, o aplicativo de M.L. tem o objetivo de identificar e agrupar as frutas da mesma variedade.

O que aplicativo faz:

- Com base nos dados introduzidos, a aplicação de ML analisa os dados.
- Em seguida, tenta identificar padrões, como por exemplo tamanhos, formatos e cores.
- Baseado nos padrões identificados irá segregar os diferentes tipos ou variedades de frutas, criando grupos específicos destas variedades.
- Por último, ele mantém o controle de todas as decisões tomadas no processo para garantir que está aprendendo.

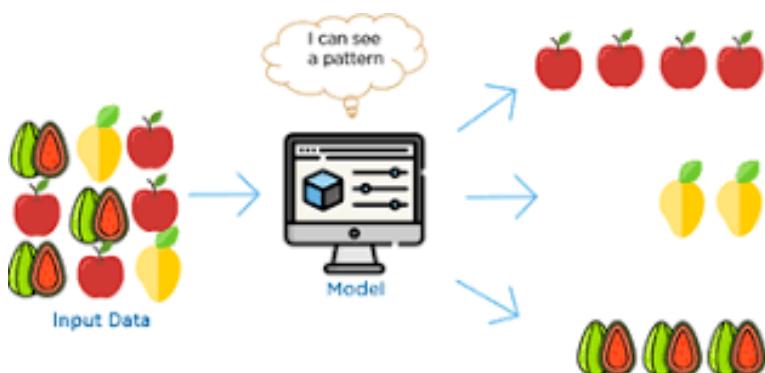


Figura 2 - Funcionamento do M.L. no processamento de imagens de frutas

Desta maneira, se um outro conjunto de dados for imputado, o sistema não irá repetir todo o processo novamente. Uma vez que aprendeu nos exemplos que experimentou, irá reutilizar o aprendizado destes tipos diferentes e dos grupos de frutas já identificados. Veja na figura abaixo, os passos de como a máquina aprende.

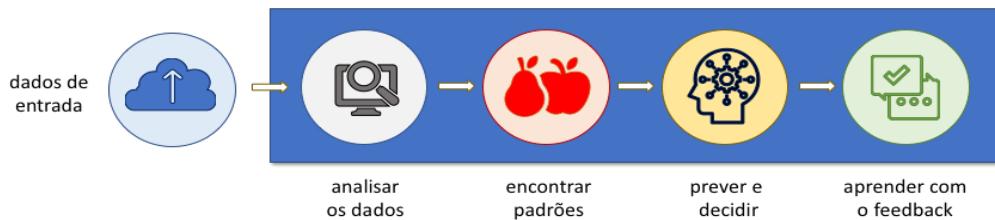


Figura 3 – Passos do aprendizado de máquina.

ABORDAGENS DE APRENDIZADO DE MÁQUINA

Existem diferentes tipos de abordagens, ou tipos de aprendizado de máquina, e que são tradicionalmente divididas em três categorias amplas.

Aprendizagem supervisionada

Nesta abordagem dizemos ao computador o que é cada entrada (qual o rótulo) e ele irá aprender quais características daquelas entradas fazem elas serem o que são. Ocorre quando o modelo aprende a partir de resultados pré-definidos. Ao computador são apresentados exemplos de entradas e suas saídas desejadas, e o objetivo é que ele aprenda uma regra geral que mapeia entradas em saídas.

O algoritmo de aprendizagem supervisionada é mais comumente utilizado, com base de dados previamente rotulados, sendo possível fazer previsões futuras.

Aprendizagem não supervisionada

A diferença da aprendizagem não supervisionada para a supervisionada é que aqui a aprendizagem ocorre com dados não rotulados, ou seja, não dizemos ao computador o que é aquela entrada.

Desta forma, na abordagem não supervisionada, nenhum rótulo é dado ao algoritmo de aprendizagem, deixando-o sozinho encontrar a estrutura em sua entrada. Neste caso, o algoritmo identifica os padrões e os organiza.

Diferentemente do supervisionado, o aprendizado não supervisionado não se baseia em dados rotulados e pode ter um objetivo em si mesmo, ou seja, o de descobrir padrões ocultos nos dados, ou ainda, um meio para um fim, o de descobrir a estrutura dos dados.

Aprendizagem por reforço

A aprendizagem por reforço é uma forma de ensinar ao computador qual ação priorizar dada uma determinada situação.

Podemos imaginar um programa responsável por dirigir um veículo autônomo. Ele deve aprender a dirigir pelas ruas e transportar seus passageiros. Existem diversas formas de otimizar esta tarefa. Por exemplo, chegar ao destino no menor tempo possível e não causar nenhum acidente. Queremos que ele saiba o que fazer conforme o que ocorre à sua volta, e preferimos que ele demore um pouco mais do que causar um acidente, por exemplo. À medida que navega no espaço do problema, o programa recebe um feedback análogo às recompensas, que ele tenta maximizar.

Uma das questões relevantes é a definir a correta solução de ML para um dado problema, especificamente qual algoritmo deve ser utilizado. Esta definição tem algumas dependências importantes:

- Declaração do problema e sua natureza. É importante antes de tudo entender qual é o problema;

- Entender os dados quanto ao tamanho, qualidade e a natureza dos dados que serão utilizados;
- Complexidade do algoritmo.

MÉTODOS E ALGORITMOS UTILIZADOS NO APRENDIZADO DE MÁQUINA

Um algoritmo é uma denominação dada em ciência da computação para uma sequência finita de ações executáveis que visam obter uma solução para um determinado tipo de problema. Algoritmos são procedimentos precisos, não ambíguos, mecânicos, eficientes e corretos". Importante destacar que algoritmos não são tipos de ML. Os algoritmos, entretanto, são métodos utilizados para a resolução de problemas. Dentro de uma visão mais ampla, vejamos agora os métodos, e alguns exemplo de algoritmos mais comuns utilizados na resolução de problemas.

Classificação

O método de classificação recai normalmente no tipo de aprendizado supervisionado. É utilizado quando a saída esperada é um “Sim” ou “Não”, ou na forma de “a” ou “b”, ou ainda, se é “verdadeiro” ou “falso”.

Exemplos de algoritmos utilizados no método de classificação:

- Árvore de decisão^[dic]
- Regressão logística^[dic]
- Random forest^[dic]
- Naive Bayes^[dic]
- KNN^[dic] – abreviação do inglês “K nearest neighbor”, ou seja, Vizinho K-mais próximo

Regressão

O método de Regressão é utilizado quando um dado numérico necessita ser previsto, como por exemplo, um investidor necessita saber o preço de ações na bolsa de valores. Neste caso, onde o preço das ações é calculado pela demanda, é utilizado normalmente o método de regressão.

Exemplos de algoritmos utilizados para o método de regressão:

- Regressão linear^[dic]
- Regressão multivariada^[dic]

Clustering ou de agrupamento

O método de Clustering, ou de Agrupamento, é um método de aprendizado não supervisionado, e é normalmente utilizado quando os dados necessitam ser organizados para encontrar padrões. Este é o método utilizado no caso de recomendação de produtos. Muitos dos aplicativos utilizados pela AMAZON, MAGALU, AMERICANAS, utilizam métodos de Clusterização para recomendar produtos aos clientes.

Um dos algoritmos utilizados para o método de clusterização:

- K means^[dic]

A figura abaixo resume e correlaciona a abordagem e os métodos básicos mais comumente utilizados na aprendizagem de máquina.

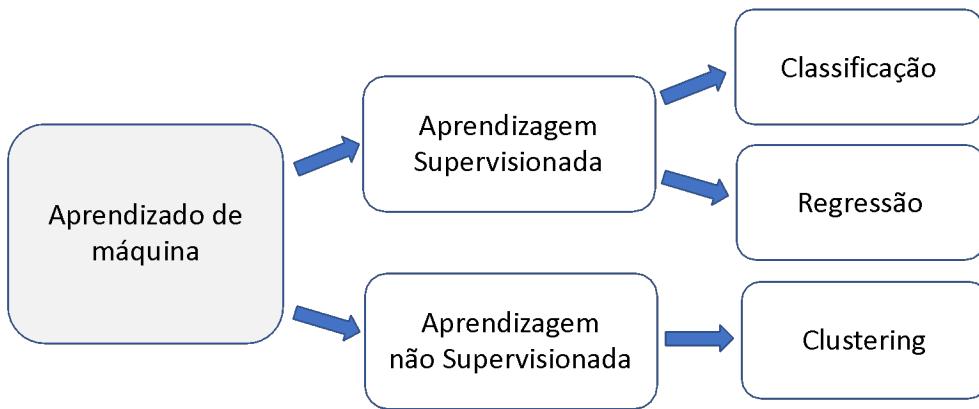


Figura 7 - Abordagens e métodos básicos

CAPÍTULO 3: BREVE RETROSPECTIVA SOBRE I.A. E M.L.

A Inteligência Artificial é definida como inteligência de máquina ou inteligência demonstrada por máquinas, em contraste com a inteligência natural exibida por humanos. O termo I.A. é frequentemente usado para descrever máquinas que imitam a capacidade cognitiva humana, funções como aprendizagem, compreensão, raciocínio e resolução de problemas (Russell e Norvig 2013). A I.A. tem duas dimensões principais, conforme apresentado abaixo na tabela 1. As definições de I.A. no topo da tabela se relacionam a processos e raciocínio, enquanto os que estão na parte inferior tratam do comportamento. As definições no lado esquerdo da tabela medem o sucesso em termos de fidelidade ao desempenho humano, enquanto os do lado direito mede contra um conceito ideal de inteligência e racionalidade.

Tabela 1: Definições de Inteligência Artificial

Pensando como humano	Pensando racionalmente
<p>"O novo e interessante esforço para fazer os computadores pensarem (...) máquinas com mentes, no sentido total e literal." (Haugenland, 1985)</p> <p>"[Automatização de] atividades que associamos ao pensamento humano, atividades como tomadas de decisões, a resolução de problemas, o aprendizado..." (Bellman, 1978)</p>	<p>"O estudo das faculdades mentais pelo uso de modelos computacionais." (Charniak e McDermott, 1985)</p> <p>"O estudo dos computadores que tornam possível perceber, raciocinar e agir." (Winston, 1992)</p>
Agindo como seres humanos	Agindo racionalmente
<p>"A arte de criar máquinas que executam funções que exigem inteligência quando executadas por pessoas." (Kurzweil, 1960)</p> <p>"O estudo de como os computadores podem fazer tarefas que hoje são desempenhadas melhor pelas pessoas." (Rich e Knight, 1991)</p>	<p>"Inteligência Computacional é o estudo dos projetos de agentes inteligentes." (Pooke et al., 1998)</p> <p>"IA...está relacionada ao um desempenho inteligente de artefatos" (Nilsson, 1998)</p>

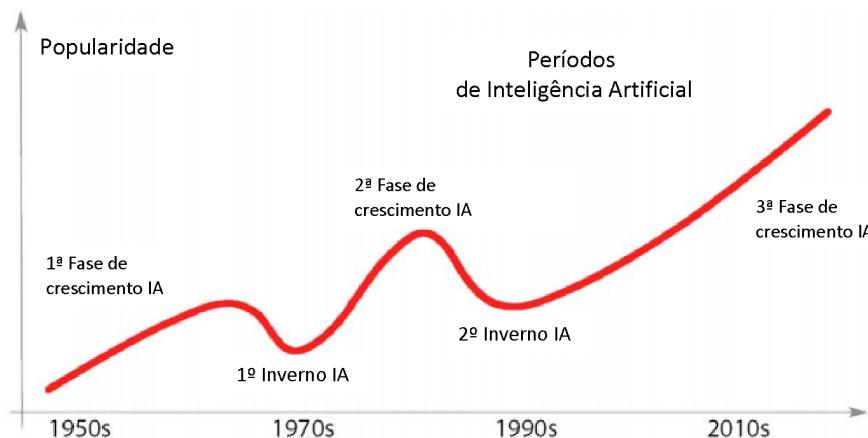
Fonte: (Russell e Norvig, 2013)

No início da década de 1950, Alan Turing propôs o famoso **Teste de Turing**^[dic] no artigo ("Computing machinery and intelligence") para fornecer uma definição satisfatória de inteligência. O computador passará no teste se um interlocutor humano, depois de propor algumas perguntas por escrito, não conseguir descobrir se as respostas escritas vêm de uma pessoa ou de um computador.

Portanto, para que o computador fosse aprovado no teste, ele precisaria ter as seguintes capacidades:

- **Processamento de Linguagem Natural (NLP)**^[dic]: para permitir que ele se comunique com sucesso em um idioma natural;
- **Representação do Conhecimento (KR)**^[dic]: para armazenar o que sabe e o que ouve;
- **Raciocínio Automatizado (AR)**^[dic]: para usar as informações armazenadas para responder a perguntas e tirar novas conclusões;
- **Aprendizagem de Máquina (ML)**: para se adaptar às novas circunstâncias e para detectar e explorar padrões.

A história da Inteligência Artificial é marcada por distintos ciclos tanto de crescimento como de desaceleração. Estes períodos em que ocorreram uma forte desaceleração, foram denominados “Inverno de I.A.”. É, sobretudo, um período de financiamento e interesses reduzidos na pesquisa de inteligência artificial. O campo passou por vários ciclos de crescimentos, seguidos de decepção e crítica, seguidos por cortes de financiamento, seguidos por anos em que foram renovados os interesses no seu desenvolvimento, conforme demonstrado no gráfico a seguir.



Fonte: (DELIPETREV, 2020 adaptado)

O início da I.A. foi realizado através do trabalho de dois pesquisadores, Warren McCulloch e Walter Pitts^[dic] em 1943. Eles propuseram um modelo de neurônios artificiais, no qual cada neurônio se caracteriza por estar “ligado” ou “desligado”, com a troca para “ligado” ocorrendo em resposta à estimulação por um número suficiente de neurônios vizinhos. Para isso, eles se basearam em três áreas do conhecimento: fisiologia básica, função dos neurônios no cérebro, a lógica proposicional, criada por Russell e Whitehead^[dic] e a teoria da computação de Turing.

Porém, o nascimento da I.A. ocorreu em 1956 com o **Seminário de Dartmouth College**^[dic]. Foi nesse seminário que o termo "Inteligência Artificial" apareceu pela primeira vez. O evento contou com 10 participantes. Alguns pesquisadores de Princeton, IBM e MIT.

Inicialmente, houve um forte entusiasmo por parte dos pesquisadores para desenvolver novos modelos e programas que possibilitasse ao computador executar

atividades humanas complexas. Em 1957, O pesquisador, Herbert Simon^[dic], fez a seguinte declaração.

“Não é meu objetivo surpreendê-los ou chocá-los, mas o modo mais simples de resumir tudo isso é dizer que agora existem no mundo máquinas que pensam, aprendem e criam. Além disso, sua capacidade de realizar essas atividades está crescendo rapidamente até o ponto – em um futuro visível – no qual a variedade de problemas com que elas poderão lidar será correspondente à variedade de problemas com os quais lida a mente humana.” (Russell e Norvig 2013).

Ele inferiu que em 10 anos, o computador seria campeão de xadrez e que poderia formular um teorema matemático significativo. Porém, ao longo dos anos os pesquisadores enfrentaram algumas dificuldades e limitações que contribuíram para o surgimento do primeiro “inverno da I.A.”, uma fase em que as pesquisas e os investimentos se arrefeceram. Esse primeiro período perdurou de 1966 até o início dos anos 80.

“O primeiro inverno da IA foi marcado por uma redução dramática nas atividades de IA na indústria e na academia. As deficiências da IA foram explicadas em dois relatórios: a) o relatório do Automatic Language Processing Advisory Committee (ALPAC) do governo dos EUA (ALPAC 1966) eb) o relatório Lighthill (Lighthill 1973) do governo britânico.” (DELIPETREV(Blagoj DELIPETREV,2020)

O relatório Lighthill, publicado pelo *British Science Research Council* intitulado “Artificial Intelligence: A General Survey” pelo Prof. Sir James Lighthill da Universidade de Cambridge em 1973, era pessimista, pois “Em nenhuma parte do campo de I.A. as descobertas feitas até agora produziram o impacto que era então prometido.”

Durante os primeiros esforços de tradução automática, um projeto subsidiado pelo National Research Council do governo americano, foi criado com o objetivo de acelerar a tradução de textos científicos russos, após o lançamento da Sputnik em 1957. O projeto baseava-se em transformações de regras gramaticais e sintáticas simples do russo para o inglês, com base em um dicionário eletrônico. Pensou-se que isso seria o suficiente para prever o significado exato das orações. Fato é que a tradução exige conhecimento profundo no assunto para solucionar ambiguidades e estabelecer o conteúdo das sentenças.

O relatório ALPAC (ALPAC 1966), concluiu que a tradução automática não proporcionou melhorias adequadas em qualidade, velocidade e custo; pelo contrário, a tradução automática era de má qualidade. Ele observou que havia tradutores suficientes disponíveis (4.000 estavam atualmente sob contrato, mas apenas 300 deles trabalhavam em média por mês).

SISTEMAS ESPECIALISTAS E I.A. SIMBÓLICA

Nos anos 80 e 90 a I.A. simbólica ou sistemas especialistas ganharam notoriedade para a resolução de problemas complexos buscando apresentar o comportamento inteligente. Este paradigma, traz uma abordagem diferente da visão conexionista (baseado no funcionamento do cérebro biológico). Na abordagem simbólica o sistema busca o comportamento inteligente através de uma base de conhecimento, ou seja, os sistemas especialistas são construídos a partir da extração desse conhecimento de um especialista humano, codificando-o de uma forma que o computador possa aplicá-lo.

Um dos sistemas especialistas mais antigos a explorar o conhecimento específico para a resolução de problemas foi o DENDRAL^[dic], desenvolvido pela a Universidade de Stanford no fim dos anos 60 (Luger,George, 2013).

A tabela abaixo mostra os principais acontecimentos relacionados à evolução da inteligência artificial entre os anos de 1970 e 1983.

Tabela 2: Principais acontecimentos da área entre 1970 e 1983.

1970	MYCIN era um sistema especialista para diagnosticar e prescrever medicamentos para meningite espinhal. Adotou um cálculo de incerteza que parecia se encaixar bem com a avaliação dos médicos sobre o diagnóstico (Shortliffe et al. 1975).
1968 - 1970	SHRDLU era um programa de linguagem natural que permitia ao usuário manter uma conversa com o computador, nomear coleções e consultar o estado de um "mundo de blocos simplificado" (Winograd 1971).

1972	Prolog é uma linguagem de programação simbólica desenvolvida e implementada em Marselha, França, por Alain Colmerauer com Philippe Roussel.
1979	O Stanford Cart conseguiu atravessar uma sala sozinho, evitando obstáculos (Moravec 1983).
1982	A "rede de Hopfield" era uma forma de rede neural que aprendia e processava informações de uma nova maneira (Hopfield 1982). A "rede Hopfield" e a "retropropagação" (Rumelhart et al. 1985) reviveram o campo da IA do conexionismo.
1983	ID3 é um algoritmo que gera uma árvore de decisão a partir de um conjunto de dados. ID3 é o precursor do algoritmo C4.5 usado em aprendizado de máquina e processamento de linguagem natural (Quinlan 1986).

Fonte: (Blagoj DELIPETREV,2020)

Já o primeiro sistema especialista comercial bem-sucedido foi o R1, que iniciou sua operação na Digital Equipment Corporation. O programa ajudou a configurar pedidos de novos sistemas de computadores. Em 1986, ele estava fazendo a empresa economizar 40 milhões de dólares por ano (Russell e Norvig 2013).

No ano de 1986, ocorreu um evento significativo para os sistemas **conexionistas**¹⁴ (sistemas baseados no funcionamento do cérebro biológico), que foi o aprimoramento do algoritmo ***Backpropagation***^[dic] (retropropagação), com resultados relevantes publicados na coletânea *Parallel Distributed Process*^[dic] (Rumelhart e McClelland, 1986).

Após a década de 1990, o termo “sistema especialista” teve origem no vocabulário técnico da Tecnologia da Informação (TI), um período de retração e baixo investimento na área, e foi referido como o segundo inverno de I.A.. Um dos principais problemas dos sistemas especialistas era a aquisição de conhecimento. A aquisição de conhecimento captura o conhecimento especializado e o representa em uma linguagem simbólica. Obter tempo e experiência de especialistas em domínio foi difícil, pois eles

são constantemente requisitados por parte de suas organizações. Portanto, a pesquisa de sistema especialista focou em ferramentas para aquisição de conhecimento, para ajudar a automatizar o processo de projeto, depuração e manutenção de regras definidas por especialistas.

Segundo Delipetrev (DELIPETREV,2020), muitos pesquisadores de I.A. na década de 1990 deliberadamente chamaram seus trabalhos por outros nomes, como informática, sistemas baseados no conhecimento, sistemas cognitivos, algoritmos de otimização ou inteligência computacional. Os novos nomes ajudaram a obter financiamento. As promessas sem sucesso decorrentes do inverno da IA continuam a assombrar a pesquisa de IA no mundo comercial.”

A tabela abaixo mostra os principais acontecimentos relacionados à evolução da inteligência artificial entre os anos de 1989 e 1998.

Tabela 3: Principais acontecimentos da área entre 1989 e 1998.

1989	Ler dígitos manuscritos usando redes neurais convulsionais. O sistema processou cerca de 10-20% dos cheques sacados manuscritos e códigos postais nos Estados Unidos entre o final dos anos 90 e o início dos anos 2000 (LeCun et al. 1989).
1989	"Aprendendo com Recompensas Atrasadas" introduziu o conceito de Q-learning, que melhora muito a praticidade e a viabilidade do aprendizado por reforço. O algoritmo Q-learning aprendeu o controle ótimo sem modelar as probabilidades de transição ou recompensas esperadas do Processo de Decisão de Markov (Watkins 1989).
1993	O cientista da computação alemão Schmidhuber resolveu uma tarefa de “aprendizado muito profundo” em 1993 que exigia mais de 1.000 camadas na rede neural recorrente (Schmidhuber 1993).
1995	Máquinas de vetores de suporte foram aplicadas à categorização de texto, reconhecimento de caracteres manuscritos e classificação de imagens (Cortes e Vapnik 1995).

1995	"No Hands Across America 3." Um carro semi autônomo dirigiu 4.501 km de costa a costa pelos Estados Unidos com direção controlada por computador. Um acelerador e freios controlados por um motorista humano.
1996	O IBM Deep Blue venceu o jogo de xadrez contra Garry Kasparov, o melhor jogador humano do mundo. O Deep Blue não usou DL ou nenhuma das técnicas de IA mais recentes. O sistema havia "aprendido" todas as partidas possíveis de xadrez e podia avaliar o presente e sugerir o próximo movimento.
1997	A arquitetura de memória de longo prazo (LSTM) melhorou a eficiência e a praticidade do RNN, eliminando o problema de dependência de longo prazo (Hochreiter e Schmidhuber 1997)
1998	O Gradient-Based Learning foi aprimorado combinando o algoritmo de descida gradiente estocástico com o algoritmo de retropropagação (LeCun et al. 1998).

Fonte: (Blagoj DELIPETREV,2020)

APRENDIZADO DE MÁQUINA E APRENDIZADO PROFUNDO (2000S – 2020S)

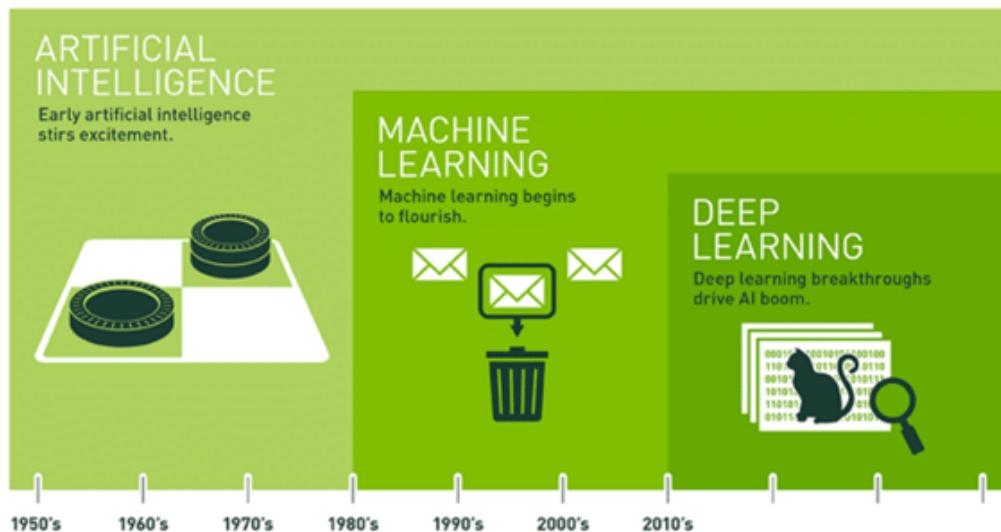
Entre os anos 2000-2010 houve um grande avanço na utilização de (machine learning ou aprendizado de máquina), as aplicações de I.A. forneceram soluções úteis para diferentes domínios incluindo: mineração de dados, robótica, logística, software bancários entre outros, utilizando modelos matemáticos cada vez mais sofisticados. Contudo, na última década ocorreu um crescimento exponencial da I.A., principalmente com a intensificação do uso de (Deep Learning ou Aprendizado profundo), técnicas geralmente utilizadas para resolução de problemas provenientes de dados não estruturados, como por exemplo: Reconhecimento de fala, classificação de imagens, segmentação de texto, filtros em redes sociais, entre outras aplicações.

Alguns fatores tecnológicos contribuíram para o rápido crescimento no uso de Machine Learning e Deep Learning. A evolução do processamento paralelo em GPU “*Graphics processing unit*” ou (*Unidades de Processamento Gráfico*), a difusão e o

acesso da Internet de banda larga associado com a telefonia móvel, redes sociais, Big Data, IoT e computação em nuvem contribuíram com aceleração desse processo. Esses avanços contribuem para que as empresas, entidades governamentais, ongs e demais agentes de outros segmentos, possam armazenar e processar uma enorme quantidade de dados.

Extrair informações e/ou padrões destes dados, representa um grande desafio e um diferencial competitivo para quem dispõem de tais meios.

Evolução da Inteligência Artificial com suas subáreas ML e DL



Fonte: (COPELAND , 2021)

O aprendizado profundo é uma subárea do aprendizado de máquina, conforme mostra a figura anterior. Suas arquiteturas são inspiradas no funcionamento do cérebro humano e são denominadas de Redes Neurais Artificiais (RNA). Cada arquitetura de RNA possui características específicas e servem para a resolução de problemas diversificados. As redes neurais profundas, redes neurais recorrentes e redes neurais convolucionais (CNN) são alguns exemplos dessas arquiteturas.

Uma outra técnica de aprendizado profundo é o *Reinforcement Learning* (Aprendizado por reforço). Aprender com as experiências, recompensas ou punições associadas é a ideia central do Aprendizado por reforço. O R.L. permite que o agente inteligente aprenda regras sofisticadas de tomada de decisão sem ter nenhum dado

histórico. Por meio dessa abordagem vários avanços importantes ocorreram na IA, como AlphaGO, que venceu o campeão GO em 2016.

Por fim, a tabela 4 traz os principais eventos que ocorreram nos anos 2000 até o momento. Porém, os eventos a seguir foram significativos e com grande repercussão acadêmica e/ou midiática:

- Em 2007 a Nvidia introduziu plataforma CUDA “*Compute Unified Device Architecture*” (*Arquitetura de Dispositivo de Computação Unificada*) foi o primeiro modelo de programação amplamente adotado para computação em GPU segundo (Sanders, et al., 2010).
- Em 2009 o conjunto de dados ImageNet foi lançado com 3,2 milhões de imagens rotuladas disponíveis para todos (Deng et al. 2009).
- O IBM Watson ganhou uma partida de Jeopardy contra Ken Jennings e Brad Rutter. Ken Jennings e Brad Rutter estavam entre os concorrentes mais bem-sucedidos do programa Jeopardy. Watson é um sistema de computação de perguntas e respostas com processamento avançado de linguagem natural, recuperação de informações, representação de conhecimento, raciocínio automatizado e resposta a perguntas. Foi um sistema de IA verdadeiramente notável combinando muitos componentes de última geração em reconhecimento de fala, síntese de voz e recuperação de informações, entre outros (Ferrucci 2012).
- AlphaGo derrotou Lee Sedol, o jogador de Go número um do mundo (Silver et al. 2016). Por causa de sua complexidade, o jogo Go foi considerado fora do alcance da IA por pelo menos mais uma década. AlphaGo foi atualizado um ano depois para um algoritmo AlphaZero generalizado e mais poderoso (Silver et al. 2017). AlphaZero aprendeu a jogar xadrez de nível mestre em apenas quatro horas e derrotou Stockfish (o melhor jogador de xadrez de IA) em uma partida de 100 jogos - sem perder um único jogo.

A tabela abaixo mostra os principais acontecimentos relacionados à evolução da inteligência artificial entre os anos de 2002 e 2019.

Tabela 4 : Principais acontecimentos da área entre 2002 e 2019:

2002	TD-Gammon alcançou desempenho como os melhores jogadores humanos no jogo de Gamão. TD-Gammon foi uma grande conquista da combinação de redes neurais e Aprendizado por Reforço (RL) com o método de jogo automático (Tesauro 2002).
2005	O robô Stanford venceu o Grande Desafio DARPA. O robô de Stanford dirigiu autonomamente por 131 milhas ao longo de uma pista deserta não ensaiada (Thrun et al. 2006).
2009	O conjunto de dados ImageNet foi lançado com 3,2 milhões de imagens rotuladas disponíveis para todos (Deng et al. 2009).
2011	O IBM Watson ganhou uma partida de Jeopardy contra Ken Jennings e Brad Rutter. Ken Jennings e Brad Rutter estavam entre os concorrentes mais bem-sucedidos do programa Jeopardy. Watson é um sistema de computação de perguntas e respostas com processamento avançado de linguagem natural, recuperação de informações, representação de conhecimento, raciocínio automatizado e resposta a perguntas. Foi um sistema de IA verdadeiramente notável combinando muitos componentes de última geração em reconhecimento de fala, síntese de voz e recuperação de informações, entre outros (Ferrucci 2012).
2012	AlexNet venceu a competição ImageNet, muitas vezes considerada como o ponto de inflexão da EAD (Krizhevsky et al. 2012).
2012	O experimento Cat aprendeu a identificar e reconhecer gatos a partir de 10.000.000 de imagens não rotuladas retiradas aleatoriamente do YouTube. O programa teve um desempenho quase 70% melhor do que as tentativas anteriores de aprendizagem não supervisionada (Le 2013).
2014	Redes Adversariais Generativas (GANs) são arquiteturas de redes neurais profundas compostas de duas redes, colocando uma contra a outra (portanto, o “adversário”). As GANs podem aprender a imitar qualquer distribuição de dados e podem gerar conteúdo como qualquer domínio: imagens, música, fala, etc. (Goodfellow et al. 2014).

2015	DeepRL dominou uma gama diversificada de jogos Atari 2600 para o nível sobre-humano com apenas os pixels brutos e pontuações como entradas. Os jogos Atari se tornaram benchmarks padrão para algoritmos de IA. A IA superou os jogadores humanos na maioria deles (Mnih et al. 2015).
2016	AlphaGo derrotou Lee Sedol, o jogador de Go número um do mundo (Silver et al. 2016). Por causa de sua complexidade, o jogo Go foi considerado fora do alcance da IA por pelo menos mais uma década. AlphaGo foi atualizado um ano depois para um algoritmo AlphaZero generalizado e mais poderoso (Silver et al. 2017). AlphaZero aprendeu a jogar xadrez de nível mestre em apenas quatro horas e derrotou Stockfish (o melhor jogador de xadrez de IA) em uma partida de 100 jogos - sem perder um único jogo.
2017	O Transformer é uma nova arquitetura DL baseada em um mecanismo de auto atenção. Transformers são algoritmos centrais em modelagem de linguagem, tradução automática e resposta a perguntas (Vaswani et al. 2017).
2017	Libratus derrotou de forma decisiva quatro profissionais humanos líderes na variante de pôquer para dois jogadores chamada heads-up no-limit Texas Hold'em (HUNL). Ao longo de quase três semanas, Libratus jogou 120.000 mãos de HUNL contra profissionais humanos, usando uma abordagem de três frentes que incluiu pré-computar uma estratégia geral, adaptando a estratégia para o jogo real e aprendendo com seu oponente. O pôquer é um jogo de informação imperfeito (Brown e Sandholm, 2018)
2018	OpenAI Five derrotou uma equipe humana amadora no Dota 2, excedendo a inteligência humana em um videogame complexo. Em relação a sucessos anteriores como Xadrez ou Go, videogames complexos capturam a bagunça e a natureza contínua do mundo real (Pachocki et a. 2018).

2019	AlphaStar derrotou um jogador profissional de ponta em StarCraft II. AlphaStar derrotou decisivamente Grzegorz "MaNa" Komincz do Team Liquid, um dos jogadores profissionais de StarCraft mais fortes do mundo com 5-0. As partidas ocorreram em condições de jogo profissional em um mapa de escada competitiva e sem quaisquer restrições de jogo (Vinyals et al. 2019).
2019	A OpenAI treinou Dactyl4, uma mão de robô com aparência humana para manipular objetos físicos com destreza sem precedentes. Dactyl é treinado inteiramente em simulação e transfere seus conhecimentos para a realidade, adaptando-se à física do mundo real. Dactyl aprende do zero usando o mesmo algoritmo RL de propósito geral.
2019	GPT-2.5 é um modelo de linguagem não supervisionado em grande escala que gera parágrafos coerentes de texto, atinge desempenho de ponta em muitos benchmarks de modelagem de linguagem e realiza compreensão de leitura rudimentar, tradução automática, resposta a perguntas e resumo - tudo sem treinamento específico para tarefas.

Fonte: (Blagoj DELIPETREV,2020)

A evolução da I.A. ocorre não somente pelos desenvolvimentos tecnológicos expostos anteriormente, mas também pelo amadurecimento e a aceleração no compartilhamento de código aberto, publicações científicas, no desenvolvimento e publicação de novos algoritmos e arquiteturas feitas por grandes empresas de tecnologias, tais como: Google, IBM, Facebook, AWS, entre outras. Também podemos citar as Universidades e indivíduos que compartilham esses conhecimentos em fóruns de discussão e outros canais de comunicação, nas mais diversas linguagens de desenvolvimento existentes.

CAPÍTULO 4: ALGUNS EXEMPLOS E APLICAÇÕES

Hoje em dia a tecnologia se mostra cada vez mais presente, e a tecnologia do Machine Learning e da Inteligência artificial podem ajudar muito por exemplo no

processo de “Democratização da Educação”, já que seus sistemas podem ser acessados e alimentados por pessoas do mundo todo.

Sobre essa ótica, o M.L. pode ser utilizado por professores e estudantes em diversas atividades, contribuindo com o desenvolvimento e a potencialidade cognitiva de alunos das mais variadas idades.

Algumas possibilidades de uso na Educação:

- Analisar redações e traçar o caminho de sucesso adequado para que os estudantes escrevam melhor, auxiliando no trabalho de professores, e mostrando novos caminhos a serem trilhados;
- Corrigir Redações e verificar se há fuga ao tema proposto. No ENEM, por exemplo, há dois avaliadores para cada redação e se não houver concordância, vai para um terceiro avaliador. Um sistema que identifica a fuga do tema pode poupar trabalho para os profissionais responsáveis pela correção.

Exemplos de aplicação utilizando os métodos: PLN, Naive Bayes e Regressão multivariada^[dic].

- Para predizer a nota da redação;
- Feedbacks imediatos, que auxiliam o aluno a entender melhor seus erros e acertos no atual aprendizado, e o contínuo trabalho para corrigi-los no mesmo momento, um sistema mais abrangente e em larga escala;
- Ao identificar a dificuldade do aluno num exercício, por exemplo, o sistema pode recomendar exercícios do mesmo assunto.

Exemplos de aplicação utilizando os métodos: Matriz TF-IDF ^[dic] produto escalar.

- Fazer análises preditivas de performance no vestibular, partindo de notas de provas e simulados;
- Avaliar o interesse do aluno pelo curso, ou seja, com a aplicação de ML no ensino EAD, poderíamos avaliar o interesse do aluno pelo aprendizado e prever se ele pretende abandonar um determinado curso por exemplo;
- Análise feita pelo sistema com relação à frequência de acessos e tempo de permanência do aluno no ambiente de aula virtual.

Exemplos de aplicação utilizando os métodos: Regressão multivariada e SVM
[\[dic\]](#) regressor.

- Identificar perfis de alunos com relação à performance e à motivação.

Exemplos de aplicação utilizando os métodos: Análise de clusters: [K Means](#)
[\[dic\]](#) e [Information Bottleneck Method](#) [\[dic\]](#)

- Auxiliar o professor a construir bancos de questões, classificando-as por tema;
- Verificar o ineditismo de uma questão no banco de questões.

Estas ferramentas proporcionam aos professores a possibilidade de reverter a situação, conversando com o aluno e entendendo o que pode ser feito para melhorar a sua interação com as atividades propostas ou lidar com suas dificuldades.

O ML também pode ser utilizado nos sistemas e-learning, trabalhando em diversas partes do processo, inclusive na personalização do conteúdo, ativando assim o interesse pelo aluno.

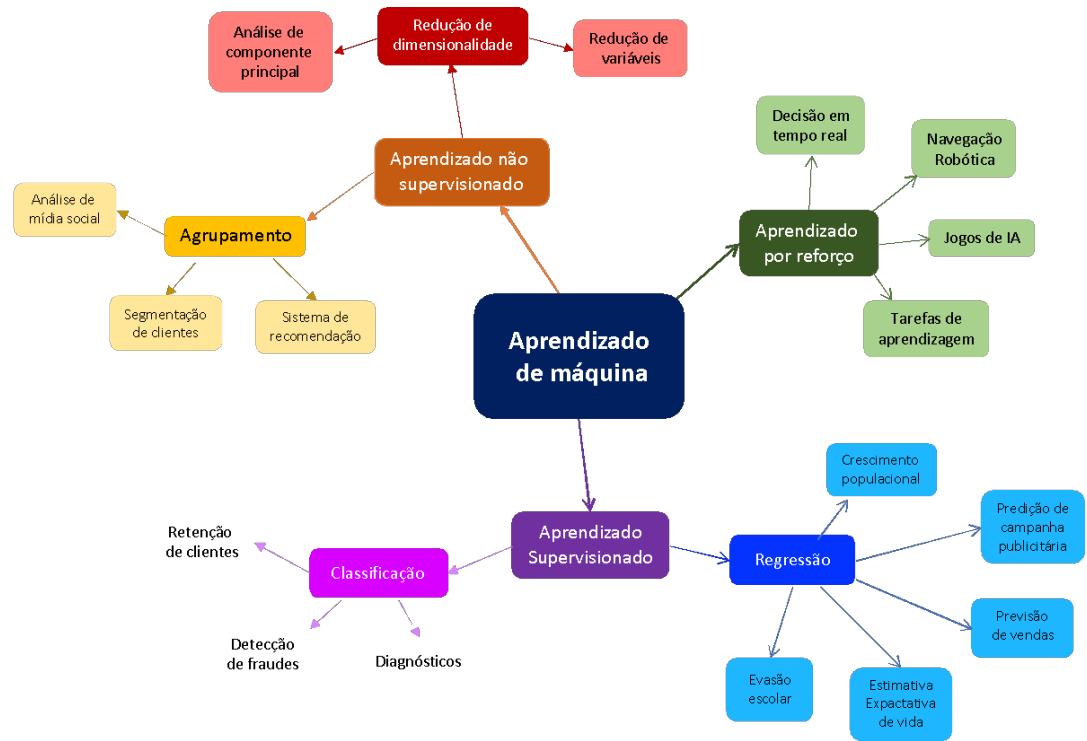
Os algoritmos, aprendem a induzir uma função hipótese capaz de solucionar um problema a partir de dados que representam instâncias do problema a ser resolvido.

Outros exemplos em que o M.L. já comprovou sua eficácia:

- Reconhecimento de Voz
- Detecção de Fraudes em Cartão de Crédito
- Previsão de doenças
- Carros Autônomos
- Diagnóstico de Câncer
- Detecção de Anomalias
- Resultados de Pesquisas na Web
- Análise de Sentimentos Baseados em Texto
- Previsão de Falhas em diversos Equipamentos
- Anúncios em tempo Real em Páginas da Web e Dispositivos Móveis
- Filtragem de Spams no e-mail
- Detecção de Invasão na Rede
- Pontuação de Crédito e atualização rápida de melhores ofertas.

CAPÍTULO 5: MAPA DE MÉTODOS E APLICAÇÕES

O mapa a seguir, apresenta os principais métodos utilizados no aprendizado de máquina e quais as principais aplicações para cada método.



REFERÊNCIAS BIBLIOGRÁFICAS

ALPAC L. Machines: Computers in Translation and Linguistics [Relatório] / Division of Behavioral Sciences. - [s.l.]: Automatic Language Processing Advisory Committee, 1966.

COPELAND , MICHAEL. 2021. blog.nvidia.com.br. Qual é a Diferença entre Inteligência Artificial, Machine Learning e Deep Learning? [Online] nvidia, 10 de 03 de 2021. <<https://blog.nvidia.com.br/2021/03/10/qual-e-a-diferenca-entre-inteligencia-artificial-machine-learning-e-deep-learning/?LinkId=100000035663020>>

DELIPETREV, Blagoj , TSINARAKIi, Chrisa e KOSTIĆ, Uroš . 2020. Historical Evolution of Artificial Intelligence.

EUR 30221EN. [Online] 28 de 02 de 2020. Acesso em: 28/02/2021. Disponível em: <<https://op.europa.eu/en/publication-detail/-/publication/6264ac29-2d3a-11eb-b27b-01aa75ed71a1/language-en>>.

Luger, George F. 2013. Inteligência Artificial. [trad.] Daniel Vieira. São Paulo: Pearson Education do Brasil, 2013.

Lighthill J. Artificial Intelligence: A Paper Symposium [Relatório]. - London: Science Research Council, 1973.

OpenCL. 2011. web.archive.org. OpenCL - The open standard for parallel programming of heterogeneous systems. [Online] OpenCL, 09 de 08 de 2011. <https://web.archive.org/web/20110809103233/http://www.khronos.org/opencl/>.

Sanders, Jason e Kandrot, Edward. 2010. CUDA by Example: An Introduction to General-Purpose GPU Programming, Portable Documents. s.l.: Addison-Wesley Professional, 2010. ISBN 0132180138, 9780132180139.

Stuart, Russell e Norvig, Peter. 2013. Inteligência Artificial. [trad.] Célia Simile. Rio de Janeiro: Elieser, 2013.

REFERÊNCIAS DAS TABELAS 2-4

Brown, N., & Sandholm, T. (2018). Superhuman AI for heads-up no-limit poker: Libratus beats top professionals. *Science*, 359(6374), 418-424.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine learning*, 20(3), 273-297.

Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., & Fei-Fei, L. (2009). Imagenet: A large-scale hierarchical image database. In 2009 IEEE conference on computer vision and pattern recognition (pp. 248-255). IEEE.

Ferrucci D., (2012). "Introduction to "this is watson"." IBM Journal of Research and Development 56, no. 3.4: 1-1

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, 9(8), 1735-1780

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. In Advances in neural information processing systems (pp. 1097-1105).

Le, Q. V. (2013). Building high-level features using large scale unsupervised learning. In 2013 IEEE international conference on acoustics, speech and signal processing (pp. 8595-8598). IEEE.

LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278-2324.

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., ... & Petersen, S. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529-533.

Moravec, H. P. (1983). The Stanford cart and the CMU rover. *Proceedings of the IEEE*, 71(7), 872-884.

Pachocki J., Brockman G., Raiman J., Zhang S., Pondé H., Tang J., Wolski. F., "OpenAI Five, 2018." URL <https://blog.openai.com/openai-five>.

Papernot, N., McDaniel, P., Goodfellow, I., Jha, S., Celik, Z. B., & Swami, A. (2016). Practical black-box attacks against deep learning systems using adversarial examples. arXiv preprint arXiv:1602.02697, 1(2), 3.

Quinlan, J. R. (1986). Induction of decision trees. *Machine learning*, 1(1), 81-106.

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1985). Learning internal representations by error propagation (No. ICS-8506). California Univ San Diego La Jolla Inst for Cognitive Science.

Schmidhuber, J. (1993). Habilitation thesis: System modeling and optimization. Page 150 ff demonstrates credit assignment across the equivalent of 1,200 layers in an unfolded RNN.

Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., Van Den Driessche, G., ... & Dieleman, S. (2016). Mastering the game of Go with deep neural networks and tree search. *Nature*, 529(7587), 484.

Shortliffe, E. H., Davis, R., Axline, S. G., Buchanan, B. G., Green, C. C., & Cohen, S. N. (1975). Computer-based consultations in clinical therapeutics: explanation and rule acquisition capabilities of the MYCIN system. *Computers and biomedical research*, 8(4), 303-320

Tesauro, G. (2002). Programming backgammon using self-teaching neural nets. *Artificial Intelligence*, 134(1-2), 181-199.

Thrun, S., Montemerlo, M., Dahlkamp, H., Stavens, D., Aron, A., Diebel, J., ... & Lau, K. (2006). Stanley: The robot that won the DARPA Grand Challenge. *Journal of field Robotics*, 23(9), 661-692.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. In *Advances in neural information processing systems* (pp. 5998-6008).

Vinyals O., Babuschkin I., Chung J., Mathieu M., Jaderberg M., Czarnecki W., Dudzik A., (2019). AlphaStar: Mastering the Real-Time Strategy Game StarCraft II. <https://deepmind.com/blog/alphastar-mastering-real-timestrategy-game-starcraft-ii/>

Watkins, C. J. C. H. (1989). Learning from delayed rewards.

Winograd, T. (1971). Procedures as a representation for data in a computer program for understanding natural language (No. MAC-TR-84). MASSACHUSETTS INST OF TECH CAMBRIDGE PROJECT MAC.

DICIONÁRIO DA NOMENCLATURA TÉCNICA, CONCEITOS E INFORMAÇÕES HISTÓRICAS

Fonte: Wikipedia-inglês

[dic] Arvore de decisão - É um mapa representativo dos possíveis resultados de uma série de escolhas relacionadas. Permite a comparação de possíveis ações com base em seus custos, probabilidades e benefícios.

[dic] Anamneses - entrevista realizada pelo médico ao seu paciente a fim de diagnosticar uma doença.

[dic] Backpropagation - Do inglês, retro propagação, é um algoritmo amplamente usado no aprendizado de máquina para treinar redes neurais.

[dic] Big Five - Conhecido como Modelo dos Cinco Grandes Fatores, surgiu por meio dos estudos da Teoria dos Traços de Personalidade, no qual descreve as dimensões humanas básicas.

[dic] Computação em nuvem - Computação em nuvem, é um termo coloquial para a disponibilidade sob demanda de recursos do sistema de computador, especialmente armazenamento de dados e capacidade de computação, sem o gerenciamento ativo direto do utilizador.

[dic] Computação paralela - O processamento paralelo é um método de computação de execução de dois ou mais processadores (CPUs) para lidar com partes

separadas de uma tarefa geral. Dividir diferentes partes de uma tarefa entre vários processadores ajudará a reduzir o tempo de execução de um programa.

[dic] Conexionismo - é um conjunto de técnicas de diferentes campos, como inteligência artificial, psicologia cognitiva, ciências cognitivas, neurociência e filosofia da mente, que modelam fenômenos mentais e de comportamento. Existem várias formas de conexionismo, sendo as mais comuns as que utilizam modelos de redes neurais.

[dic] Dartmouth College Conference 1956 - O Projeto de Pesquisa de Verão de Dartmouth em Inteligência Artificial foi um workshop de verão de 1956 amplamente considerado como o evento fundador da inteligência artificial como um campo. Foi conduzido pelo cientista John McCarthy.

[dic] Herbert Simon - Foi um economista e pesquisador estadunidense. Desenvolveu trabalhos nos campos de psicologia cognitiva, informática, administração pública, sociologia económica, e filosofia. Por vezes, descreveram-no como um polímata.

[dic] Inverno de IA - Na história da inteligência artificial, um inverno de IA foi um período que houve redução do financiamento e do interesse nas pesquisas de inteligência artificial. O termo foi cunhado por analogia à ideia de um inverno nuclear, em referência a Guerra Fria. O campo de IA passou por vários ciclos de grande crescimento, seguidos de decepções, críticas e cortes de financiamento e, posteriormente, seguidos por financiamentos de pesquisa renovados anos ou décadas depois.

[dic] John Flavell - é um psicólogo americano especializado em desenvolvimento cognitivo infantil. Conduziu uma extensa pesquisa sobre metacognição e teoria da mente da criança. Uma de suas contribuições mais famosas para o campo é seu trabalho sobre o desenvolvimento da compreensão infantil da distinção entre aparência e realidade.

[dic] John McCarthy - foi um cientista da computação estadunidense. Foi conhecido pelos estudos no campo da inteligência artificial e por ser o criador da linguagem de programação Lisp.

[dic] K means - é um método de quantização vetorial, originário do processamento de sinais, que visa particionar n observações em k clusters em que cada observação pertence ao cluster com a média mais próxima (centros de cluster ou centroide de cluster), servindo como um protótipo de o cluster.

[dic] KNN - Abreviação do inglês “K Nearest Neighbor”, ou seja, Vizinhos k-mais próximos.

[dic] Metacognição - A metacognição foi definida nos anos de 1970 por John Flavell (Stanford University) como o conhecimento que as pessoas têm sobre seus próprios processos cognitivos e a habilidade de controlar esses processos, monitorando, organizando, e modificando-os para realizar objetivos concretos.

[dic] Matriz TF-IDF - Abreviação de termo frequência-frequência inversa do documento, é uma estatística numérica que se destina a refletir a importância de uma palavra para um documento em uma coleção ou corpus. É frequentemente usado como um fator de ponderação em pesquisas de recuperação de informações, mineração de texto e modelagem de usuário.

[dic} Meta-memória - O termo meta-memória se refere ao conhecimento objetivo de um indivíduo sobre os processos da memória, como por exemplo, o grau de dificuldade de uma determinada tarefa ou quais as estratégias apropriadas para realizá-la (Flavell, 1971; Flavell & Wellman, 1977).

[dic] Naive Bayes - Método de machine learning que usa as frequências das ocorrências em uma base de dados para prever uma variável de interesse. Seu nome vem do modelo estatístico bayesiano. O termo *naive*, que significa *ingênuo* em inglês, se deve ao fato de que o Naive Bayes não parte de um “grau de certeza” inicial; a análise dos dados inicia sem qualquer certeza *a priori*, e esse grau é construído analisando as frequências presentes nos dados disponíveis.

[dic] Processamento de Linguagem Natural (NLP) - , É um campo do aprendizado de máquina com a capacidade de um computador entender, analisar, manipular e, potencialmente, gerar linguagem humana.

[dic] Raciocínio Automatizado (AR - Automatic reasoning) - É uma subárea da IA que estuda formas de simular raciocínio lógico por meio de métodos computacionais.

[dic] Representação do Conhecimento (KR – knowledge reasoning) - É uma subárea de pesquisa em inteligência artificial. A pesquisa na área de representação do conhecimento tenta responder como é representado o nosso conhecimento, se as pessoas representam conhecimento todas da mesma maneira, se existe alguma forma de representar qualquer coisa, ou ainda, como programas inteligentes devem representar conhecimento.

[dic] Regressão linear - é um método estatístico utilizado para investigar a relação existente entre variáveis, sendo essas variáveis chamadas de *variáveis dependentes* ou *independentes*. Essa análise é realizada através da construção de uma equação, denominada modelo.

[dic] Random forest – Floresta aleatória é um algoritmo de aprendizado supervisionado, baseado no método de regressão. O algoritmo Random Forest opera construindo várias árvores de decisão durante o tempo de treinamento e produzindo a média das classes como a previsão de todas as árvores.

[dic] Regressão logística – é uma análise que nos permite estimar a probabilidade associada à ocorrência de determinado evento em face de um conjunto de variáveis explanatórias, tendo como vantagens a facilidade para lidar com variáveis independentes categóricas e a classificação de indivíduos em categorias. Possui alto grau de confiabilidade.

[dic] Regressão multivariada - A regressão multivariada é uma coleção de técnicas estatísticas que constroem modelos que descrevam de maneira razoável relações entre

várias variáveis explicativas de um determinado processo. A diferença entre a regressão linear simples e a multivariada é que nesta são tratadas duas ou mais variáveis explicativas.

[dic] Sinapse - É uma região de proximidade entre um neurônio e outra célula por onde é transmitido o impulso nervoso. Um neurônio faz sinapses com diversos outros neurônios.

[dic] SVM Support Vector Machine - No aprendizado de máquina, as máquinas de vetores de suporte, são modelos de aprendizagem supervisionada com algoritmos de aprendizagem associados que analisam dados para classificação e análise de regressão.

[dic] Teste de Turing - O teste foi introduzido por Alan Turing em seu artigo de “Computing Machinery Inelligence”, o qual propôs a investigação centrada na questão “se é possível ou, não máquina apresentarem comportamento inteligente”.

[dic] Information Bottleneck - O método de gargalo de informação é uma técnica da teoria da informação projetado para encontrar a melhor troca entre precisão e complexidade (compressão) ao resumir (por exemplo, agrupamento) uma variável aleatória X, dada uma distribuição de probabilidade conjunta p (X, Y) entre X e uma variável relevante observada Y - e descrito como fornecendo "uma estrutura surpreendentemente rica para discutir uma variedade de problemas no processamento e aprendizagem de sinais".

[dic] Warren McCulloch e Walter Pitts - Desenvolveram o artigo clássico sobre “um cálculo lógico das ideias imanentes na atividade nervosa”, em 1943, tendo sido o ponto de partida de muitas investigações teóricas até os dias atuais: a ideia básica era que a ativação de um neurônio dentro de um cérebro representa a verdade real de uma proposição sobre o mundo exterior.

[dic] George F. Luger - Teve um compromisso de pesquisa de pós-doutorado de cinco anos no Departamento de Inteligência Artificial da Universidade de Edimburgo, na Escócia. Em Edimburgo, ele trabalhou em vários dos primeiros sistemas especialistas,

participou do desenvolvimento e teste da linguagem de computador Prolog e continuou sua pesquisa em modelagem computacional de desempenho de resolução de problemas humanos. Atualmente é Professor de Ciência da Computação, Linguística e Psicologia na Universidade do Novo México. Ele recebeu seu PhD da Universidade da Pensilvânia.

ONLINE

CERTIFICADO I2ΔI AI TECHNOLOGIES FOUNDATIONS

16 horas aula em 4 Módulos

Consulte as turmas abertas em www.i2ai.org/course/list/



1º módulo

RPA

Robotic Process Automation

Prof. Alexandre Seidl



2º módulo

Machine Learning

Prof. Diego Nogare



3º módulo

Visão Computacional

Prof. Alessandro Faria



4º módulo

NLP

Natural Language Processing

Prof. Alexandre Romeira



I2ΔI

A Connected AI World

SOBRE OS AUTORES

Este livro foi escrito de forma colaborativa pelos membros do Comitê de *Machine Learning* da I2AI. Colaboraram para esta publicação:

Alexandre Nicolau – <https://www.linkedin.com/in/alexandrenicolau/>

Experiência de 25+ anos em grandes desafios de projetos de tecnologia como implantações de ERP, integrações de sistemas legados, desenvolvimento de algoritmos de aprendizado de máquina, desenvolvimento de projetos de NLP (processamento de linguagem natural) e principalmente implementar a cultura de tomada de decisão baseada em dados, aproximando a TI das áreas de negócios.

Pós-graduado em Big Data e Data Science pela Faculdade de Informática e Administração Paulista (FIAP) e certificado XBA – Xponential Business Administration pela StartSe e Nova School of Business and Economics (Lisboa – Portugal).

Arnaldo de Paula Couto – <https://www.linkedin.com/in/arnaldo-de-paula-couto-9407932/>

Carreira desenvolvida nas áreas técnicas e administrativas de empresas nacionais e multinacional, com mais de 30 anos de sólida experiência em planejamento, gerenciamento, formação e liderança de equipes multidisciplinares de hardware, software para implantação de projetos, instalação e prestação de serviços para produtos de TI e eletroeletrônicos.

A experiência adquirida e os resultados conquistados ao longo deste período, fornecem os subsídios, segurança e motivação necessárias para assumir outros desafios para atuar na gestão de quaisquer processos de atendimentos a clientes, independente dos produtos e serviços envolvidos.

Claudio Cardozo – <https://www.linkedin.com/in/claudiocardozo/>

Entusiasmo e genuíno interesse pela Ciência da Computação, com mais de 30 anos de atuação na área, iniciando na automação industrial, passando pela área de embedded

systems em tempo real, em sistemas de defesa e finalmente desde 2004 na área corporativa em projetos da área financeira. Sólidos conhecimentos em todas as etapas do ciclo de desenvolvimento de software trabalhando em plataformas Web e Mobile e metodologias ágeis.

Como CTO na Zipdin, estruturei e montei toda a TI a partir do zero, atuando em planejamento estratégico, infraestrutura, arquitetura estrutural e de sistemas, membro do board, gestão de equipes, orçamentos da área, melhorias contínuas, visão holística do processo produtivo buscando adequações no médio longo prazo, combinando Inovação, AI/ML com sistemas de tomada de decisão e MVP com as demandas futuras da startup / Fintech e SCD. Avaliação / Implantação de produtos de fornecedores, contratos de prestação de serviços, etc. E continuo implementando código!

Daniela Jacobovitz – <https://www.linkedin.com/in/daniela-jacobovitz-b284a963/>

Doutora em Mecânica Estatística e Redes Neurais pela USP São Carlos. Realizou pós-doutorado na Tel Aviv University e também no Instituto de Química da USP de São Carlos. Atualmente, é cientista de dados na Educacross e na Barbato Estudos de Engenharia, além de trabalhar como professora colaboradora da Universidade Paulista.

Danielle Monteiro – <https://www.linkedin.com/in/danimonteirodba/>

Mestra em Engenharia da Computação, TEDx Speaker, autora do blog e do canal DB4Beginners.com, criadora da Dani.Academy.

Após anos como desenvolvedora, já foi DBA, arquiteta e engenheira de dados, agora é consultora de dados.

Ganhadora dos prêmios como MongoDB Champion, Associada Notável da I2AI, Women in IA (prêmio concedido pela I2AI), Microsoft Regional Director, Microsoft MVP, William Zola (prêmio de inovação da MongoDB), MongoDB Female Innovator, Microsoft Innovative Educator Expert.

Palestrante internacional, foi a primeira mulher brasileira a palestrar no MongoDB World (New York), palestrou no Oracle Code One (São Francisco), e no PHP Benelux (Bélgica). Além disso é instrutora oficial do LinkedIn Learning.

Dionisio Gava Junior – <https://www.linkedin.com/in/dionisio-gava-junior-14442aa/>

Carreira desenvolvida nas áreas de Tecnologia e Operações, tendo ocupado cargos executivos na indústria financeira. Atuou como Sênior Manager, Diretor de Tecnologia, CIO e COO em grandes instituições financeiras como Banco Santander, Banco Citibank e Banco Fibra. Desde 1996, liderou diversos projetos de aquisições, fusões, renovação tecnológica e operacional. Atualmente é sócio-diretor da DGA Consult, empresa dedicada a Cultura e Desenvolvimento Organizacional, Transformação Digital e Métodos Ágeis. Concomitante a carreira profissional é doutorando em Administração na linha de Gestão da Inovação na FEI (2020-2023), Mestre em Tecnologia Gestão, Desenvolvimento e Formação, pelo Centro Estadual Tecnológico Paula Souza (2010), com MBA Executivo em Marketing pelo IBMEC (2001), Administrador de Empresas graduado pela FAAP (1981). Concomitante a carreira profissional, é pesquisador no Centro Paula Souza em Gestão Estratégica da Tecnologia da Informação (CNPQ), professor pleno na FATEC-SP desde 1984, nas disciplinas de Sistemas Operacionais, Arquitetura de Computadores e Sistemas Integrados de Gestão. No curso de Ciência de Dados da FATEC Cotia ministra Ciência de Dados e o Marketing Digital. É associado da I2AI atuando desde 2020 no comitê Machine Learning.

Edson Souza Bessa – <https://www.linkedin.com/in/edson-souza-bessa/>

Profissional de tecnologia da informação, com foco em sustentação à ambientes distribuídos de integração sistêmica (Middleware). Possui mais de 10 anos de experiência na área em projetos de grande porte em diferentes segmentos tais como: bancário, telecomunicações, setor de seguros e varejo. Graduou-se pela Fatec-Mauá como Tecnólogo em Informática para Gestão de Negócios (2011), é pós-graduando em Inteligência Artificial com ênfase em Deep Learning, pelo programa de educação continuada Poli-USP (2022). É apaixonado por novas tecnologias e deseja contribuir para que as organizações tomem decisões baseadas em dados através do uso de ciência de dados e IA. Membro do comitê de Machine Learning desde 2020, contribui na difusão do conhecimento de Inteligência Artificial, através da associação I2AI.

Hamilton Tenório da Silva – <https://www.linkedin.com/in/hamiltontenoriodasilva/>

Desenvolvedor full-stack. Trabalhos com bancos de dados relacionais ou não relacionais.

Conhecimento de ambiente em nuvem (AWS, GCP, Azure, Watson).

Experiência em Inteligência Artificial, Aprendizado de Máquina, Redes Neurais. Analista de dados e Analista de negócios.

Conhecimento de ferramentas de visualização de dados (DataStudio, PowerBI, Tableau++).

Empreendedor com várias iniciativas de startups tecnológicas.

Co-Fundador da ONG Politicus (aplicativo web para promover a participação cidadã).

Desenvolvedor de aplicativos para celular sendo vários para uso público.

Idealizador, criador, pesquisador e editor de site de controle social (atividade voluntária).

Membro associado do I2AI.

Participação em concursos de tecnologia (NASA, Behind the Code IBM, Cidades Inteligentes Curitiba, Shawee, Ignite Microsoft, etc.).

Luiz Henrique de O. Bueno – <https://www.linkedin.com/in/luiz-henrique-sc/>

Descobri a Ciência de Dados por acaso em 2015. Comecei por curiosidade e descobri um universo em que posso, com base em dados, ajudar pessoas e empresas no desenvolvimento de seus negócios. Atualmente estudo Pós-graduação em Ciência de Dados PUC-RIO, presto serviço como instrutor na IMPACTA e desenvolvo pequenos projetos em Machine Learning, Data Analysis, DevOps e sou Membro do comitê Machine Learning da I2AI.